

Classificação de Gêneros Musicais com Comitê de Classificadores

Aplicação de Ensemble Learning para Predição de Gêneros Musicais

utilizando Dados do Spotify

09 de Junho de 2026

INTEGRANTES DO GRUPO

Gustavo Rodrigues Azevedo Lima

RA 82515519

João Victor da Silva Gomes

RA 825123590

Natalia da Silva Melo

RA 825134003

Asafe Alves Octaviani

RA 825157068

Lucas Henrique Noronha dos Santos

RA 824145088

Guilherme Rodrigues dos Santos

RA 826186263

Vinicius de Barros Alves

RA 825224255

Introdução e Motivação

Crescimento do Streaming

Plataformas como Spotify, Apple Music e Deezer acumulam centenas de milhões de usuários ativos, gerando demanda crescente por sistemas de recomendação inteligentes.



Importância da Categorização

A classificação precisa de gêneros musicais é essencial para personalizar playlists, melhorar a descoberta de músicas e aumentar o engajamento dos usuários.



Desafio da Classificação

A classificação manual é inviável em grande escala. Gêneros musicais têm fronteiras subjetivas e características sonoras que se sobrepõem, exigindo abordagens inteligentes de Machine Learning.



Objetivo do Projeto

Desenvolver um sistema automatizado de classificação de gêneros musicais utilizando Ensemble Learning — combinando múltiplos classificadores para obter predições mais robustas e precisas a partir de características sonoras do Spotify.



Dataset e Atributos

■ Dataset: Spotify All Time Top 100 Songs (Kaggle)

Variável Alvo: **primary_genre**

Gênero musical principal da faixa — classe a ser prevista pelo modelo

Atributo	Descrição	Escala
bpm	Batidas por minuto — ritmo da música	0 – 200
danceability	Adequação para dança (ritmo, beat, regularidade)	0 – 100
energy	Intensidade e atividade perceptual	0 – 100
valence	Positividade musical (alegre vs. triste)	0 – 100
acousticness	Nível de presença de instrumentos acústicos	0 – 100
loudness	Volume médio em decibéis	-60 – 0 dB
speechiness	Presença de palavras faladas na faixa	0 – 100
instrumentalness	Ausência de vocais (instrumental)	0 – 100

Pipeline de Pré-processamento

■ Limpeza e Valores Ausentes

Identificação e remoção de registros incompletos. Verificação da integridade do dataset garantindo que nenhum campo crítico contenha valores nulos.

1

■ Seleção de Atributos

Seleção das 8 variáveis independentes mais relevantes: bpm, danceability, energy, valence, acousticness, loudness, speechiness e instrumentalness.

2

■ Padronização (StandardScaler)

Normalização das features para média 0 e desvio padrão 1, eliminando viés causado por diferenças de escala entre os atributos (ex: bpm vs loudness em dB).

3

■ Codificação dos Gêneros

Conversão da variável-alvo textual (primary_genre) para representação numérica via Label Encoding, possibilitando o uso pelos algoritmos de classificação.

4

■ Agrupamento Inteligente de Classes

Unificação de subgêneros similares em categorias maiores para reduzir ruído, melhorar a separabilidade entre classes e aumentar o desempenho dos classificadores.

5

Dados Brutos

Limpeza

Seleção

Padronização

Codificação

Agrupamento

Pronto

Classificadores Individuais

5 algoritmos implementados - mínimo exigido: 3

K-Nearest Neighbors

Classifica uma amostra pela maioria dos K vizinhos mais próximos no espaço de features. Intuitivo e eficaz para fronteiras de decisão não-lineares.

n_neighbors = 7

weights = distance

Métrica: Euclidiana

KNN

Decision Tree

Cria regras de decisão hierárquicas dividindo o espaço de features recursivamente. Alta interpretabilidade, porém suscetível a overfitting.

max_depth = 8

min_samples_leaf = 2

random_state = 42

DT

Naive Bayes

Aplica o Teorema de Bayes assumindo independência entre features. Rápido e eficiente para dados contínuos, mas limitado por correlações.

Gaussian NB

Assume independência

Probabilístico

NB

Support Vector Machine

Encontra o hiperplano de margem máxima que separa as classes. Excelente desempenho em espaços de alta dimensão.

Kernel = RBF

C = 1.0

probability = True

SVM

Random Forest

Conjunto de árvores de decisão treinadas em subconjuntos aleatórios. Reduz overfitting por bagging e oferece alta robustez.

100 árvores

max_depth = 10

Bagging + Feature Random

RF

Ensemble Learning

Hard Voting

Votação Majoritária

Cada classificador emite um voto para uma classe. A classe com maior número de votos é selecionada como predição final. Simples, rápido, sem necessidade de probabilidades.

Soft Voting

Média de Probabilidades

Cada classificador fornece probabilidades para cada classe. A média ponderada das probabilidades determina a predição final. Mais refinado — considera a confiança de cada modelo.

Stacking



Meta-Classificador (Melhor Resultado)

Os modelos base geram predições que alimentam um meta-classificador (Regressão Logística). Ele aprende a combinar as saídas de forma otimizada, obtendo os melhores resultados gerais.

Diagrama — Fluxo do Ensemble (Stacking)



Avaliação de Desempenho

Métricas Utilizadas: Cross-Val 5-Fold Accuracy Precision Recall F1-Score Matriz de Confusão

Modelo	Tipo	Accuracy	Precision	Recall	F1-Score
KNN	Individual	48,00%	68,98%	48,00%	52,17%
Decision Tree	Individual	48,00%	70,18%	48,00%	53,60%
Naive Bayes	Individual	36,00%	69,18%	36,00%	38,73%
SVM ★	Individual	52,00%	78,35%	52,00%	55,93%
Random Forest ★	Individual	56,00%	59,83%	56,00%	57,29%
Hard Voting (Majoritária)	Comitê	48,00%	80,90%	48,00%	53,07%
Soft Voting (Ponderada)	Comitê	56,00%	74,11%	56,00%	60,36%
Stacking ■	Comitê	76,00%	77,52%	76,00%	74,60%

★

Melhores Individuais

Random Forest e SVM apresentaram os melhores desempenhos entre os modelos individuais.

↑

Ensemble Superior

O Ensemble superou a média dos modelos individuais, demonstrando o poder da combinação.

■

Stacking Vencedor

Stacking obteve 76% de acurácia — muito acima da média individual (~48%).

■

Maior Robustez

Múltiplos classificadores aumentaram a capacidade de generalização e reduziram o overfitting.

■ Conclusão do Projeto

■ Objetivo Alcançado

- Sistema de classificação automática de gênero musical desenvolvido com sucesso.
- Cinco classificadores individuais implementados e avaliados rigorosamente.
- Todas as etapas do projeto A3 atendidas.

■ Eficiência do Ensemble

- Stacking atingiu 76% de acurácia — melhor resultado geral.
- Hard e Soft Voting também superaram a média dos modelos individuais.
- Combinação de classificadores aumentou robustez e generalização.

■ Aplicações Reais

- Sistemas de recomendação musical (Spotify, Deezer, Apple Music).
- Organização automática de acervos e playlists personalizadas.
- Melhoria na experiência e retenção de usuários em plataformas.

■ Próximos Passos

■ Ampliar a base de dados

Aumentar a diversidade de músicas e melhorar o treinamento do modelo com datasets maiores como o Million Song Dataset.

■ Testar algoritmos mais avançados

Implementar XGBoost e Redes Neurais (LSTM/CNN) para buscar maior precisão e capturar padrões temporais na classificação.

Objetivo: aumentar a precisão e a robustez do sistema de predição de gêneros musicais.