

Relatório do Projeto A3 - Inteligência Artificial

Classificação de Gêneros Musicais com Comitê de Classificadores

Aplicação de Ensemble Learning para Predição de Gêneros Musicais utilizando Dados do Spotify

Instituição: Universidade São Judas Tadeu

Disciplina: Inteligência Artificial

Integrantes:

- Gustavo Rodrigues Azevedo Lima (RA 82515519)
- João Victor da Silva Gomes (RA 825123590)
- Natalia da Silva Melo (RA 825134003)
- Asafe Alves Octaviani (RA 825157068)
- Lucas Henrique Noronha dos Santos (RA 824145088)
- Guilherme Rodrigues dos Santos (RA 826186263)
- Vinicius de Barros Alves (RA 825224255)

1. Introdução

O mercado de streaming de áudio (como Spotify, Apple Music e Deezer) apresentou um crescimento massivo, com uma gigantesca quantidade de faixas inseridas diariamente. Nesse cenário, classificar músicas manualmente tornou-se inviável em grande escala. Os gêneros musicais possuem fronteiras subjetivas e características acústicas sobrepostas, o que torna a Inteligência Artificial a solução ideal para automatizar esse processo.

O objetivo deste projeto é desenvolver um pipeline de Machine Learning capaz de prever o gênero musical com base em atributos de áudio, utilizando a técnica de Comitê de Classificadores (Ensemble Learning) para maximizar a precisão.

2. Descrição da Base de Dados

Os dados foram extraídos de uma base pública da plataforma Kaggle, contendo dados estruturados do Spotify. Os atributos extraídos e utilizados como variáveis independentes incluem características acústicas geradas pela plataforma, tais como:

- **Danceability:** Dançabilidade da faixa.
- **Energy:** Intensidade e atividade percebida.
- **Loudness:** Volume geral da faixa em decibéis.
- **Speechiness:** Presença de palavras faladas.
- **Acousticness:** Grau de acusticidade.
- **Instrumentalness:** Previsão de ausência de vocais.
- **Liveness:** Probabilidade da faixa ter sido gravada ao vivo.
- **Valence:** Positividade musical transmitida.
- **Tempo:** Velocidade da música em Batidas Por Minuto (BPM).



3. Definição do Problema (Target)

- **Variável Target (Alvo):** O gênero musical da faixa (uma variável categórica multiclasse).
- **Variáveis Independentes (Features):** Os atributos sonoros numéricos extraídos descritos na seção anterior.
- **Tipo de Problema:** Aprendizado Supervisionado de Classificação Multiclasse, onde o modelo tenta inferir a classe (gênero) a partir de premissas (características acústicas).

4. Pré-processamento

Nesta etapa, o tratamento e a preparação dos dados foram realizados para otimizar o aprendizado dos modelos:

- **Análise Exploratória de Dados (EDA):** Avaliação das distribuições e correlações das features para entender o comportamento das variáveis.
- **Tratamento de Desbalanceamento:** Aplicação do algoritmo SMOTE (Synthetic Minority Over-sampling Technique) para gerar dados sintéticos das classes minoritárias, garantindo que o comitê não ficasse tendencioso para os gêneros mais frequentes.
- **Padronização:** Utilização de técnicas de escala (StandardScaler) nas features sonoras, garantindo que os dados estivessem na mesma métrica, o que é um requisito fundamental para algoritmos baseados em distância ou gradiente descendente.



5. Modelagem

Superando o requisito mínimo estipulado no enunciado de 3 classificadores, foram implementados e avaliados 5 modelos individuais distintos. A base de dados foi rigorosamente dividida em conjuntos de treino e teste para garantir a validação justa e precisa de cada modelo de forma isolada.

6. Construção do Comitê


O conceito de Ensemble Learning foi aplicado unindo as forças dos modelos individuais para mitigar os erros de classificação. Foram implementadas 3 abordagens principais de comitê:

1. **Hard Voting (Votação por Maioria):** Cada classificador vota de forma independente em um gênero, e a classe que recebe o maior número de votos é a previsão final.
2. **Soft Voting (Votação por Probabilidade):** É calculada a média das probabilidades atribuídas por cada modelo a cada possível gênero musical, sendo selecionado o gênero que obtiver a maior média geral.
3. **Stacking (Empilhamento):** As previsões dos 5 classificadores base foram utilizadas como novos atributos de entrada para um meta-classificador final, que foi treinado para ponderar qual modelo base apresenta maior confiabilidade para determinados padrões de som.


7. Resultados e Métricas

A avaliação comparativa dos modelos revelou uma melhoria substancial ao utilizar as estratégias de comitê, superando o desempenho dos classificadores treinados individualmente:

- **Desempenho Individual:** A média de acurácia dos modelos isolados atingiu aproximadamente 48%.
- **Desempenho do Comitê (Stacking):** A técnica de Stacking alcançou uma acurácia notável de 76%, representando um salto expressivo de desempenho e o melhor resultado do projeto.



O uso de múltiplas métricas de validação, incluindo relatórios contendo Precisão, Recall, F1-Score e matrizes de confusão, evidenciou que as estratégias de Ensemble não apenas elevaram a taxa de acertos, mas também aumentaram de forma considerável a robustez da generalização dos modelos.



8. Discussão

A classificação automática de gêneros musicais constitui uma tarefa de alta complexidade devido à subjetividade e à forte sobreposição de características acústicas entre diferentes estilos (por exemplo, Rock e Metal frequentemente apresentam níveis de *Energy* e *Loudness* estatisticamente muito semelhantes). O notável sucesso da estratégia de Stacking (atingindo 76% de acurácia) é justificado pelo fato de que o meta-classificador transcende a simples ponderação média, conseguindo aprender as fraquezas específicas e os pontos fortes matemáticos de cada modelo isolado. Essa abordagem efetivamente atenuou o problema do overfitting em classes dominantes e resultou em um poder preditivo superior em dados nunca vistos.

9. Conclusão

Os objetivos traçados para a Avaliação A3 foram plenamente atendidos. O sistema desenvolvido demonstrou de forma clara e empírica que os comitês de classificadores conseguem resolver problemas dotados de alta complexidade dimensional e subjetividade humana com considerável sucesso analítico. Na prática, este modelo emula a arquitetura de sistemas industriais empregados nas principais plataformas de streaming da atualidade.

Trabalhos Futuros: Como sugestões para dar continuidade e aprofundamento ao estudo, recomenda-se a ampliação do escopo do dataset (como o *Million Song Dataset*) e a experimentação com algoritmos ainda mais avançados, incluindo XGBoost e redes neurais profundas focadas em dados sequenciais (RNNs/LSTMs ou CNNs em espectrogramas de áudio), buscando alcançar níveis ainda maiores de precisão preditiva.